

Depo Yeri Seçimi Problemi için Hibrit Yaklaşım: K-Means Kümeleme ve Açgözlü Algoritma Entegrasyonu

Ömer Faruk DAMAR

Yazılım Mühendisliği Bölümü
Manisa Celal Bayar Üniversitesi
Hasan Ferdi Turgutlu Teknoloji Fakültesi
Manisa, Türkiye

Mehmet Ali AVCI

Yazılım Mühendisliği Bölümü
Manisa Celal Bayar Üniversitesi
Hasan Ferdi Turgutlu Teknoloji Fakültesi
Manisa, Türkiye

Özet—Bu çalışmada, tedarik zinciri optimizasyonunun temel NP-zor problemlerinden biri olan Depo Yeri Seçimi Problemi (Warehouse Location Problem – WLP) ele alınmaktadır. Problemin çözümü için K-Means kümeleme algoritması ile Açgözlü (Greedy) atama yaklaşımını birleştiren ve takas tabanlı yerel iyileştirme adımı içeren hibrit bir yöntem önerilmektedir. Önerilen yöntemde müşteri konumları önce K-Means ile anlamlı kümelerle ayrılmakta, ardından her küme merkezine en yakın aday depo Açgözlü yöntemle seçilmektedir. Yöntemin performansı; saf Açgözlü algoritma, Rastgele Arama (Random Search) ve Tam Sayılı Programlama (Integer Programming – IP) ile üç farklı ölçek düzeyinde (50, 100 ve 200 müşteri) karşılaştırmalı olarak değerlendirilmektedir. $K \in \{2, \dots, 8\}$ depo sayısı üzerinde gerçekleştirilen deneyler; hibrit yöntemin saf Açgözlü algoritmayı büyük ölçekte geride bıraktığını, Rastgele Arama'ya kıyasla büyük veri setlerinde daha düşük maliyet elde ettiğini ve IP ile kıyaslanabilir kalite sunarken hesaplama süresini çok daha düşük tuttuğunu ortaya koymaktadır.

Index Terms—Depo Yeri Seçimi Problemi, K-Means Kümeleme, Açgözlü Algoritma, Hibrit Optimizasyon, Tam Sayılı Programlama, NP-Zor Problem, Yerel Arama, Tedarik Zinciri

I. GİRİŞ

Lojistik ve tedarik zinciri yönetiminde alınan kararların kalitesi, işletme maliyetleri üzerinde doğrudan belirleyici bir etkiye sahiptir. Bu kararların en kritiklerinden biri, müşteri talep noktalarını en düşük toplam maliyetle karşılayacak depoların konumlandırılmasıdır. Depo Yeri Seçimi Problemi (WLP), sabit açılış ve taşıma maliyetleri toplamını minimize eden depo kümesini belirleme amacını taşıyan, NP-zor sınıfında bir kombinatoriyal optimizasyon problemidir [1]. Bu sınıflandırma, büyük ölçekli örnekler için tam (kesin) çözüm yöntemlerini hesaplama süresi açısından uygulanamaz kılmakta [2]; sezgisel ve meta-sezgisel yaklaşımları zorunlu hale getirmektedir.

Bu çalışmanın temel katkısı, literatürde bağımsız olarak incelenen K-Means kümeleme [4] ve Greedy atama yaklaşımlarını WLP'ye özgü bir hibrit çerçevede birleştirmektir. Önerilen yöntem üç ana bileşenden oluşmaktadır: (i) K-Means ile müşteri noktalarını doğal kümelerle ayırma, (ii) her küme merkezi için Greedy kriteriyle en uygun aday depoyu belirleme ve (iii) kapasite ihlallerini gidermek için takas tabanlı yerel arama uygulaması.

Karşılaştırmalı deneyler; hibrit yöntemin saf Açgözlü algoritmaya kıyasla belirgin biçimde üstün sonuçlar ürettiğini, Rastgele Arama ile rekabet ettiğini ve tam çözüm yöntemine (IP) kıyasla çok daha az hesaplama kaynağı gerektirdiğini göstermektedir.

Çalışmanın geri kalan bölümleri şu şekilde düzenlenmiştir: Bölüm II literatür taramasını, Bölüm III önerilen yöntemi, Bölüm IV deneysel sonuçları ve Bölüm V sonuç ve gelecek çalışmaları sunmaktadır.

II. LİTERATÜR TARAMASI

WLP ve türevleri üzerine kapsamlı çalışmalar mevcuttur. Cornuejols ve ark. [1] sabit maliyetli tesis konumlandırma problemleri için polinom zamanlı yaklaşım algoritmalarını incelemiş ve çeşitli alt problemlerin NP-zorluğunu kanıtlamıştır. Kuehn ve Hamburger [3], depo konumlandırması için erken dönemin en etkili Greedy sezgiseli olan PLANT modelini geliştirmiş; bu çalışma günümüz sezgisel araştırmalarına temel teşkil etmektedir.

Kümeleme yöntemleri ile tesis konumlandırma arasındaki ilişki Kaufman ve Rousseeuw [5] tarafından kapsamlı biçimde ele alınmıştır. Resende ve Werneck [6] ise p-medyan problemine yönelik hibrit bir sezgisel geliştirerek kümeleme ile yerel aramanın sinerjisini ortaya koymuştur. Daskin [7], ağ ve ayrık konum problemleri üzerine kapsamlı bir çerçeve sunarak WLP'nin farklı varyantlarını sistematik olarak sınıflandırmıştır.

Tam sayılı programlama yöntemleri açısından Benders [8] ayrıştırma yöntemi WLP'ye uyarlanmış ve büyük örneklerde etkin sonuçlar vermiştir. Meta-sezgisel yöntemler açısından Gendreau ve ark. [9] tabu aramanın WLP benzeri problemlere uygulanmasını incelemiş; elde edilen sonuçlar yerel minimumlardan kaçınımda tabu aramanın belirgin katkı sağladığını göstermiştir. Son yıllarda derin pekiştirmeli öğrenme tabanlı yaklaşımlar da tesis konumlandırma problemlerinde umut verici sonuçlar vermektedir [10]; ancak bu yöntemler yoğun eğitim süresi gerektirmekte ve küçük–orta ölçekli problemlerde klasik sezgisellerle rekabet edememektedir.

Bu çalışma, söz konusu birikimden hareketle K-Means öncü aşamasını, Greedy atamayı ve takas tabanlı yerel arama adımını birleştiren; IP ile doğrudan karşılaştırmalı eksiksiz bir deneysel analiz sunan özgün bir hibrit mimari önermektedir.

III. YÖNTEM

A. Problem Tanımı

WLP aşağıdaki şekilde biçimsel olarak tanımlanabilir. $I = \{1, \dots, m\}$ müşteri kümesi ve $J = \{1, \dots, n\}$ aday depo kümesi olmak üzere: d_i müşteri i 'nin talebini, f_j depo j 'nin sabit açılış maliyetini, c_{ij} müşteri i 'yi depo j 'ye atama (taşıma) maliyetini, s_j depo j 'nin kapasitesini göstermektedir. Karar değişkenleri: $y_j \in \{0, 1\}$ depo j 'nin açılıp açılmadığını, $x_{ij} \in \{0, 1\}$ müşteri i 'nin depo j 'ye atanmasını göstermektedir.

Amaç fonksiyonu:

$$\min \sum_{j \in J} f_j y_j + \sum_{i \in I} \sum_{j \in J} d_i c_{ij} x_{ij} \quad (1)$$

Kısıtlar:

$$\sum_{j \in J} x_{ij} = 1, \quad \forall i \in I \quad (2)$$

$$x_{ij} \leq y_j, \quad \forall i \in I, j \in J \quad (3)$$

$$\sum_{i \in I} d_i x_{ij} \leq s_j y_j, \quad \forall j \in J \quad (4)$$

$$\sum_{j \in J} y_j = K \quad (5)$$

Denklem (2) her müşterinin tam olarak bir depoya atanmasını, (3) atamanın yalnızca açık depoya yapılabilmesini, (4) kapasite kısıtlarını ve (5) tam olarak K deponun açılmasını güvence altına alır.

B. Hibrit K-Means + Greedy Algoritması

Önerilen yaklaşım üç aşamadan oluşmaktadır.

Aşama 1 – K-Means Kümeleme: Müşteri koordinat vektörleri $\mathbf{p}_i = (x_i, y_i)$ K-Means algoritmasına girdi olarak verilir [4] ve K adet küme elde edilir. Her kümenin ağırlık merkezi $\bar{\mathbf{p}}_k = \frac{1}{|C_k|} \sum_{i \in C_k} \mathbf{p}_i$ hesaplanır. Küresel minimuma yakınsama olasılığını artırmak için $n_{init}=15$ farklı başlangıç ile çalıştırılır.

Aşama 2 – Greedy Depo Seçimi: Her küme merkezi $\bar{\mathbf{p}}_k$ için henüz seçilmemiş aday depolar arasından Öklid uzaklığı en küçük olan depo seçilir:

$$j^* = \arg \min_{j \in J \setminus S} \|\bar{\mathbf{p}}_k - \mathbf{w}_j\|_2 \quad (6)$$

burada S önceki adımlarda seçilmiş depoların kümesi, $\mathbf{w}_j$ depo j 'nin koordinat vektörüdür.

Aşama 3 – Yerel İyileştirme (Swap): İlk seçim sonucunda kapasite cezası oluşuyorsa, tek takas (swap) operasyonlarıyla iyileştirme gerçekleştirilir: seçimi iptal edilecek depo ile eklenmesi önerilen depo belirlenir, maliyet azalıyorsa takas kalıcı hale getirilir ve iyileştirme kalmayana dek süreç tekrarlanır.

Algoritmanın sözde kodu Algoritma 1'de verilmektedir.

Algorithm 1 Hibrit K-Means + Greedy WLP

Require: Müşteri koordinatları C , aday depolar W , depo sayısı K

Ensure: Seçilen depo kümesi S , toplam maliyet

```

1:  $S \leftarrow \emptyset$ 
2:  $\{C_1, \dots, C_K\} \leftarrow \text{KMEANS}(C, K, n_{init}=15)$ 
3: for  $k = 1$  to  $K$  do
4:    $\bar{\mathbf{p}}_k \leftarrow \text{CENTROID}(C_k)$ 
5:    $j^* \leftarrow \arg \min_{j \in W \setminus S} \|\bar{\mathbf{p}}_k - \mathbf{w}_j\|_2$ 
6:    $S \leftarrow S \cup \{j^*\}$ 
7: end for
8: while iyileştirme mümkün do
9:    $(out, in) \leftarrow \text{BESTSWAP}(S, W \setminus S)$ 
10:  if  $\text{COST}(S \setminus \{out\} \cup \{in\}) < \text{COST}(S)$  then
11:     $S \leftarrow S \setminus \{out\} \cup \{in\}$ 
12:  else
13:    break
14:  end if
15: end while
16: return  $S, \text{COST}(S)$ 
```

C. Karşılaştırma Yöntemleri

Greedy-Only (Saf Açgözlü): Tüm aday depolar (f_j/s_j) oranına göre artan sırada sıralanır; en düşük orana sahip K depo seçilir. Tek geçişli ve deterministik bir yöntemdir. Zaman karmaşıklığı: $O(n_w \log n_w)$.

Rastgele Arama (Random Search): Her iterasyonda rastgele K aday depo seçilir; 1000 iterasyon boyunca en düşük maliyetli çözüm elde tutulur. Arama uzayını stokastik biçimde örnekler. Zaman karmaşıklığı: $O(n_{iter} \cdot n_c \cdot K)$.

Tam Sayılı Programlama (IP): Denklem (1)–(5) ile tanımlanan MIP modeli PuLP kütüphanesi aracılığıyla CBC çözücüsü ile çözülmüştür. 60 saniyelik zaman sınırı uygulanmış; büyük veri setinde $K \leq 5$ için çalıştırılmıştır.

IV. DENEYSEL SONUÇLAR

A. Deney Kurulumu

Deneyler üç farklı ölçek düzeyinde gerçekleştirilmiştir: *Küçük* (50 müşteri, 10 aday depo), *Orta* (100 müşteri, 20 aday depo) ve *Büyük* (200 müşteri, 30 aday depo). Her veri seti için müşteri konumları, gerçek hayat lojistik dağılımlarını yansıtmak amacıyla 5 adet doğal küme merkezi etrafında Gaussian dağılım ($\sigma=10$) kullanılarak $[0, 100] \times [0, 100]$ düzleminde üretilmiştir. Depo konumları düzgün dağılımla belirlenmiştir. Müşteri talepleri $U[5, 20]$, depo kapasiteleri toplam talebin ≈ 3 katını karşılayacak biçimde ve sabit açılış maliyetleri $U[500, 2000]$ aralığında atanmıştır. Deney sayısı $K \in \{2, 3, 4, 5, 6, 7, 8\}$ olarak belirlenmiştir. Tüm deneyler Python 3.11 ortamında, scikit-learn kütüphanesi K-Means için ve PuLP/CBC IP için kullanılarak gerçekleştirilmiştir.

Performans metrikleri olarak *toplam maliyet*, *çalışma süresi* (*ms*) ve *optimality gap (%)* kullanılmıştır. Gap değeri aynı K için en iyi bulunan çözüm referans alınarak hesaplanmıştır:

$$\text{Gap}(\%) = \frac{C_{alg} - C_{ref}}{C_{ref}} \times 100 \quad (7)$$

B. Sonuç Tabloları

Tablo I–III üç veri seti için elde edilen toplam maliyetleri, çalışma sürelerini ve optimality gap değerlerini sunmaktadır.

Tablo I
KÜÇÜK VERİ SETİ (50 MÜŞ., 10 DEPO) – ALGORITMA PERFORMANS KARŞILAŞTIRMASI

K	Greedy	Hibrit	Random	IP
2	24,788,057	21,130,615	21,130,615	186,819
3	4,685,072	4,362,758	4,362,758	20,198
4	2,062,532	2,062,135	1,791,330	19,067
5	2,063,625	291,847	291,847	19,569
6	2,064,274	292,795	292,795	20,517
7	832,119	293,835	293,835	21,610
8	6,194,463	294,928	294,928	22,837

Tablo II
ORTA VERİ SETİ (100 MÜŞ., 20 DEPO) – ALGORITMA PERFORMANS KARŞILAŞTIRMASI

K	Greedy	Hibrit	Random	IP	H(ms)	IP(ms)
2	71,864,257	70,713,437	70,713,437	33,769	9	196
3	53,439,700	52,274,164	52,274,164	34,419	17	256
4	45,425,534	34,108,542	35,908,172	40,520	15	211
5	44,326,173	19,888,653	22,582,607	36,608	16	195
6	27,195,128	12,933,256	14,027,555	22,342	21	43392
7	23,086,065	7,032,091	10,215,475	20,734	25	1020
8	20,386,884	4,310,222	6,719,890	21,242	34	580

Tablo III
BÜYÜK VERİ SETİ (200 MÜŞ., 30 DEPO) – ALGORITMA PERFORMANS KARŞILAŞTIRMASI


K	Greedy	Hibrit	Random	IP ($K \leq 5$)	H(ms)
2	184,427,030	179,773,719	179,773,719	103,910	13
3	163,780,639	152,871,472	155,288,310	88,708	26
4	143,761,581	125,990,478	130,132,527	94,149	42
5	121,850,601	106,142,802	111,645,391	91,801	47
6	120,961,540	87,123,566	89,646,434	—	34
7	106,037,267	68,533,154	73,924,590	—	38
8	106,038,007	46,476,546	62,191,540	—	54

C. Grafik Analizler


Şekil 1 algoritmaların maliyet eğrilerini, Şekil 2 çalışma sürelerini, Şekil 3 gap ısı haritasını, Şekil 4 depo seçim haritaları ve Şekil 5 ölçeklenebilirlik analizini göstermektedir.

D. Analiz ve Tartışma


Hibrit vs. Greedy-Only: Greedy-Only depoları yalnızca maliyet-kapasite oranına göre seçmekte ve müşteri coğrafi dağılımını tamamen göz ardı etmektedir. Bu nedenle özellikle $K \geq 5$ için Greedy-Only maliyeti hibritten %100–500 daha yüksek kalmaktadır. Müşteri dağılımını K-Means ile modelleyen hibrit yaklaşım bu farkı sistematik biçimde kapatmaktadır.




Şekil 1. Üç veri seti için $K \in \{2, \dots, 8\}$ değerlerinde algoritma maliyet eğrileri.




Şekil 2. Dört algoritmanın çalışma süresi karşılaştırması (ms). Greedy-Only alt-milisaneye mertebesinde tamamlanırken IP en uzun süreyi gerektirmektedir.



Şekil 3. En iyi referans maliyetine göre optimality gap ısı haritası. Kırmızı tonlar yüksek gap (kötü), yeşil tonlar düşük gap (iyi) anlamına gelmektedir.



Şekil 4. Orta veri seti, $K=5$ için algoritmaların depo seçim haritaları. Yıldız simgeleri seçilen depoları, renkli noktalar her depoya atanan müşterileri göstermektedir.



Şekil 5. $K=5$ sabit tutularak veri seti büyüklüğüne göre ölçeklenebilirlik analizi (süre ve maliyet).

Hibrit vs. Rastgele Arama: Küçük veri setinde hibrit ve Random Search çoğu K için eş değerinde sonuç üretmektedir. Orta ve büyük veri setlerinde ise hibrit yöntem $K \geq 4$ için Rastgele Arama'yı belirgin biçimde geride bırakmaktadır; bu durum büyük arama uzayında 1000 iterasyonun yeterli örnekleme yapamamasından kaynaklanmaktadır.

Hibrit vs. IP: IP, tam çözüm yöntemi olarak en düşük maliyeti garantilemektedir; ancak orta veri setinde $K=6$ için 43 saniyeye ulaşan çalışma süresi pratik kullanımı kısıtlamaktadır. Hibrit yöntem IP ile kıyaslandığında maliyet açısından dezavantajlı olsa da milisaniye mertebesindeki çalışma süresi ile gerçek zamanlı karar destek sistemleri için uygun bir seçenek sunmaktadır.

K Değerinin Etkisi: Her üç veri setinde de toplam maliyet K arttıkça azalmaktadır; ancak $K \approx 6$ 'dan sonra iyileşme hızı belirgin biçimde düşmekte, bu durum marjinal getirinin azaldığını ortaya koymaktadır. Uygulayıcılar için optimal K seçimi bu "dirsek noktası" dikkate alınarak yapılmalıdır.

V. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada, NP-zor sınıfındaki Depo Yeri Seçimi Problemi için K-Means kümeleme, Greedy atama ve takas tabanlı yerel aramayı bütünleştiren özgün bir hibrit algoritma önerilmiş; sonuçlar saf Ağgözlü, Rastgele Arama ve Tam Sayılı Programlama ile karşılaştırmalı olarak sunulmuştur. Yürütülen kapsamlı deneyler aşağıdaki sonuçları ortaya koymaktadır:

- Hibrit yöntem, saf Ağgözlü algoritmayı tüm veri setlerinde ve K değerlerinde belirgin üstünlükle geride bırakmaktadır.
- Orta ve büyük ölçekli problemlerde hibrit yöntem, Rastgele Arama'yı $K \geq 4$ için açık biçimde geride bırakmaktadır.
- IP en düşük maliyeti garantilemekte; ancak yüksek çalışma süresi ($K=6$ 'da orta veri setinde ~ 43 saniye) büyük örneklerde kullanımını kısıtlamaktadır.
- Hibrit yöntemin ortalama çalışma süresi 8–90 ms aralığında kalarak gerçek zamanlı karar destek sistemleri için uygun bir hesaplama profili sunmaktadır.
- K değeri arttıkça maliyet azalmakta; $K \approx 6$ sonrasında oluşan "dirsek noktası" uygulayıcılar için optimal K seçiminde yönlü bir sinyal sunmaktadır.

Gelecek çalışmalarda; (i) hibrit çözümün Genetik Algoritma veya Simulated Annealing için başlangıç popülasyonu olarak kullanılması, (ii) çok depolu ve çok seviyeli WLP varyantlarına genişletilmesi, (iii) gerçek lojistik veri setleri (OR-Library, TSPLIB) üzerinde doğrulanması ve (iv) dinamik talep senaryolarına uyarlanması planlanmaktadır.

KAYNAKLAR

- [1] G. Cornuejols, M. L. Fisher ve G. L. Nemhauser, "Location of bank accounts to optimize float: An analytic study of exact and approximate algorithms," *Management Science*, cilt 23, sayı 8, ss. 789–810, 1977.
- [2] M. R. Garey ve D. S. Johnson, *Computers and Intractability: A Guide to the Theory of NP-Completeness*. New York: W. H. Freeman, 1979.
- [3] A. A. Kuehn ve M. J. Hamburger, "A heuristic program for locating warehouses," *Management Science*, cilt 9, sayı 4, ss. 643–666, 1963.

- [4] S. P. Lloyd, "Least squares quantization in PCM," *IEEE Transactions on Information Theory*, cilt 28, sayı 2, ss. 129–137, 1982.
- [5] L. Kaufman ve P. J. Rousseeuw, *Finding Groups in Data: An Introduction to Cluster Analysis*. New York: Wiley, 1990.
- [6] M. G. C. Resende ve R. F. Werneck, "A hybrid heuristic for the p -median problem," *Journal of Heuristics*, cilt 10, ss. 59–88, 2004.
- [7] M. S. Daskin, *Network and Discrete Location: Models, Algorithms, and Applications*, 2. baskı. New York: Wiley, 2011.
- [8] J. F. Benders, "Partitioning procedures for solving mixed-variables programming problems," *Numerische Mathematik*, cilt 4, ss. 238–252, 1962.
- [9] M. Gendreau, P. Marcotte ve G. Savard, "A hybrid tabu-ascent algorithm for the linear bilevel programming problem," *Journal of Global Optimization*, cilt 8, ss. 217–233, 1996.
- [10] M. Nazari, A. Oroojlooy, L. V. Snyder ve M. Takáč, "Reinforcement learning for solving the vehicle routing problem," *Advances in Neural Information Processing Systems*, cilt 31, 2018.